סיכום בסטטיסטיקה – גל אור

מה זה בכלל בדיקת השערות?

היכולת להסיק מה קורה באוכלוסייה הכללית על סמך מדגם הרבה יותר קטן. לכן ניתן לאסוף מדגם קטן, לבצע עליו מחקר ומהמסקנות שיתקבלו להסיק מה קורה בכלל האוכלוסייה ממנה נלקח המדגם.

מה עושים בבדיקת השערות?

- 1. נגדיר מראש מהי האוכלוסייה הרלוונטית למחקר שלנו (למשל י כללית- מעל גיל 18, אוכלוסייה ספציפית- חולי איידס מעל גיל 40). המסקנות שנקבל יהיו רלוונטיות עבור האוכלוסייה שהגדרנו בלבד.
- 2. מהאוכלוסייה שהגדרנו ניקח קבוצה של אנשים שתייצג מדגם קטן מכלל האוכלוסייה. המדגם צריך היות קטן, מקרי ומייצג(ככל שהמדגם גדול הוא יותר טוב אך תמיד יחשב כקטן ביחס לאוכלוסייה).
 - .3 נבצע ניתוח סטטיסטי על המדגם שלנו שממנו נסים מסקנות.
 - לאחר קבלת המסקנות מהניתוח הסטטיסטי על המדגם נבצע תהליך של הכללה של המסקנות לאוכלוסייה כולה. כלומר נאמר שמה שהתקבל עבור המדגם הקטן כנראה רלוונטי גם עבור כלל האוכלוסייה שממנה נלקח המדגם ברמת ביטחון מסוימת (לא בוודאות).

שלב א: ניסוח השערות

תהליך בדיקת ההשערות מתחיל בניסוח שתי השערות מנוגדות (H מהמילה היפותזה = השערה):

HO – המצב הקיים הידוע באוכלוסייה (הנחת המוצא). שאנחנו מתחילים לחקור אנו חייבים להניח שהמצב הקיים לא עולה בקנה אחד עם מה שאנחנו חושבים שיקרה.(בד"כ מצביעה על היעדר קשר)

H1 – השערת החוקר , ההשערה המחדשת אותה אנו רוצים לאשש. השערה זו תמיד תהיה מנוגדת להשערת H0.

בפועל אנו ננסח את השערת החוקר בלבד, כלומר את השערת H1 , כלומר אילו קשרים אני מצפים לקבל במחקר שלנו. "מאחורי הקלעים" קיימת השערת H0 שהיא ההשערה המנוגדת להשערת H1.

ההשערה חייבת לכלול את המרכיבים הבאים:

- 1. לפחות שני משתנים.
- 2. ציון הקשר המצופה, כלומר את כיוון הקשר שאנו מצפים למצוא.
 - 3. להיזהר מניסוח סיבתי (א' גורם לב').

<u>סוגי השערות:</u>

- 1. **השערה חד צדדית –** בעלת כיוון ברור של אופי הקשר בין משתנים.
 - .Yל X יימצא קשר **חיובי** בין Y לY. •
 - .Yל X יימצא קשר **שלילי** בין X ל
- 2. **השערה דו צדדית –** ללא כיוון ברור של אופי הקשר בין המשתנים. (השערה כללית שקשה להגיד עליה משהו חד משמעי)
 - .Yל X יימצא קשר **כלשהו** בין X לY.

<u>איך מכריעים בין שתי השערות?</u>

כדי להכריע בין H0 לבין H1 עורכים **מבחן סטטיסטי**.

התוצאה של המבחן הסטטיסטי הינה מהי ההסתברות שהנתון שחישבנו מהמדגם ייצג את (ישתייך ל) השערת HO ? כלומר מכיוון שהשערת ה-0 היא המוצא, אני לוקחים את הנתון שחישבנו מהמדגם ושואלים איפה אותו נופל על פני ההתפלגות של השערת ה-0 (מהי ההסתברות שאותו נתון ייפול על HO).

קוראים להסתברות זו "מובהקות המבחן" או p-value בקיצור Pv.cck שההסתברות הזו נמוכה יותר, המשמעות היא שהמדגם הזה פחות שייך ל- H0 ויותר שייך ל- H1.

נרצה לקבוע את הגבול Xc (תחום חלקי) שיבחין לנו בין מצב בו השערת ה-0 נדחית או נלקחת.

. אם ממוצע המדגם \overline{X} נופל בתחום כלומר $\overline{X}>X_c$ דוחים את השערת H1 נלקחת ממוצע המדגם לופל בתחום כלומר

.H1 ולקבל את H0 האיקס שאם ממוצע המדגם $ar{X}$ יהיה גבוהה ממנו אז נוכל לדחות את - Xc

מבחן Z – חד צדדי

- משתנה רציף.
- כאשר יש כיוון להשערה חדשה (אותה אנו בודקים) ביחס להשערת המקור (אותה אנו רוצים לדחות).
 - . $ar{X}$ כאשר נתונה לנו סטיית התקן באוכלוסייה σ וממוצע המדגם ullet

:'דרך א

1. נחשב את ערכו של Xc ע"י הנוסחה:

$$X_c = \mu_0 \pm Z_{1-\alpha} * \frac{\sigma}{\sqrt{n}}$$

- .0-התוחלת\הממוצע לפי השערת ה- μ_0
- .0- מת מובהקות, הסיכוי שנדחה את השערת ה- α
 - .סטיית התקן באוכלוסייה $-\sigma$
 - . גודל המדגם -n
- .-ם בהתאם להשערה האם היא גדולה מ- או קטנה מ- \pm
- . אם מתקיים H1 והשערת $\overline{X} > X_c$ אם מתקיים 2

:'דרך ב

- . pnorm : R ע"י הפונקציה בשפת ערכו של $ar{X}$ עד לסוף הגרף) ע"י הפונקציה בשפת ב- P_v 1.
 - . אם מתקיים P_v דוחים את השערת H1 נלקחת מתקיים $\alpha>P_v$

<u>מבחן Z – דו צדדי</u>

: Xc שינוי בדרך חישוב הערך של

$$X_c = \mu_0 \pm Z_{1-\frac{\alpha}{2}} * \frac{\sigma}{\sqrt{n}}$$

לבסוף בודקים אם התוחלת נמצאת בטווח של הרווח סמך השערת H0 נלקחת, אחרת השערת H1 נלקחת.

מבחן T – חד צדדי

- משתנה רציף
- התקן כטיית התקן כמדגם S וממוצע המדגם לנו סטיית התקן במדגם S וממוצע העונה סטיית התקן באוכלוסייה.
 - . df = n-1 הבדיקה תלויה ברמות החופש

:'דרך א

: t ע"י הנוסחה ובעזרת טבלת Xc ע"י הנוסחה ובעזרת טבלת

$$X_c = \mu_0 \pm t_{1-\alpha,df} * \frac{s}{\sqrt{n}}$$

.0- התוחלת\הממוצע לפי השערת ה $-~\mu_0$

.0- מת מובהקות, הסיכוי שנדחה את השערת ה- α

רמות החופש. – df

סטיית התקן במדגם. -S

. גודל המדגם -n

.- בהתאם להשערה האם היא גדולה מ- או קטנה מ- \pm

. אם מתקיים H1 נלקחת את השערת $ar{X} > X_c$ אם מתקיים .2

:'דרך ב

- . $t_{1-lpha,df}$ את הערך של t נחשב בעזרת טבלת.
- : נחשב את הערך של $t_{statistic}$ ע"י הנוסחה 2

$$t_{statistic} = \frac{\bar{x} - \mu}{\frac{S}{\sqrt{n}}}$$

: נבדוק

נלקחת. H1 והשערת H0 דוחים את השערת במקרים ל $t_{statistic} > t$ נלקחת מתקיים - האם מתקיים ל $t_{statistic} < t$ דוחים את השערת H1 נלקחת. במקרה השלילי - האם מתקיים

מבחן T – דו צדדי

: Xc שינוי בדרך חישוב הערך של

$$X_c = \mu_0 \pm t_{1-\frac{\alpha}{2},df} * \frac{s}{\sqrt{n}}$$

לבסוף בודקים אם התוחלת נמצאת בטווח של הרווח סמך השערת H0 נלקחת, אחרת השערת H1 נלקחת.

מבחן חי בריבוע – Chi Squared Test

<u>לבדיקת טיב התאמה(תיאוריה מול מדגם)</u>

- מבחן זה בא לבדוק האם אוכלוסייה מסוימת מתפלגת לפי התפלגות נתונה.
 למספר קטגוריות ויש לבדוק האם תוצאות המדגם תואמות להתפלגות הנתונה.
 - משתנה לא רציף, לא נורמלי.
 - כאשר המשתנה הוא קטגורי (קבוצות כדורגל, סוגי דם וכו').
 - בהינתן התפלגות קטגורית תיאורטית של כלל האוכלוסייה ובנוסף התפלגות קטגורית של מדגם
 כלשהו, מטרת המודל לבדוק כמה שונה התפלגות המדגם מהתיאוריה.
 - לבדיקת ההשערות במודל זה נסמן:

<u>בהתאם לתיאוריה על כלל אוכלוסייה:</u>, Expected

.(0-ההסתברות באחוזים של כל קטגוריה בתיאוריה (לפי השערת ה- $P_{expected,i}$

 $n*P_{expected,i}$ מספר הדגימות שהינו מצפים לקבל בתיאוריה בקטגוריה i מספר הדגימות שהינו מצפים לקבל בתיאוריה

<u>כלומר תוצאות בהתאם למדגם מתוך האוכלוסייה:</u>

. במדגם ווזים של כל קטגוריה – ההסתברות באחוזים – $P_{observed,i}$

. i מספר הדגימות שקיבלנו בפועל בקטגוריה – X_i

. גודל המדגם -n

השערות המבחן:

. observed ~ expected כלומר המשתנה מתפלג לפי התיאוריה , $m_i = p_i * n$: H0

. כלומר המשתנה מתפלג אחרת מהתיאוריה. $m_i \neq p_i * n$: H1

כלל ההכרעה : דרך א':

1. הערך הקריטי נקבע על סמך התפלגות חי בריבוע. התפלגות זו היא אסימטרית חיובית ותלויה -1 בדרגות החופש -1 (-1 מספר הקטגוריות).

במידה ויש יותר מ2 סוגי הסתברויות אז נחשב

. df = (number of groups - 1)X(number of alternative distributions - 1)

: נחשב את ערכו של x^2 ע"י הנוסחה .2

$$x^{2} = \sum_{i=1}^{k} \frac{(\text{Observed} - \text{Expected})^{2}}{\text{Expected}} = \sum_{i=1}^{k} \frac{(x_{i} - m_{i})^{2}}{m_{i}} = \sum_{i=1}^{k} \frac{x_{i}^{2}}{m_{i}} - n$$

 $: x^2$ ע"י טבלת x_c^2 ע"י טבלת .3

$$x_c^2 = x^2 (df, 1 - \alpha)$$

:או לחילופין ע"י תוכנת R והפונקציה הבאה

$$x_c^2 = qchisq(df, 1 - \alpha)$$

.4 לבסוף בודקים : אם מתקיים $x^2 > x_c^2$ השערת והשערת 14 נלקחת.

דרך ב':

 $: \mathit{R}$ בתוכנת) בתוכנת (השטח מתחת לגרף) בתוכנת 1.

$$P_{y} = pchisq(x^{2}, df, tail = false)$$

2. לבסוף בודקים:

אם מתקיים $P_v < lpha$ השערת H נדחית והשערת $P_v < lpha$

n	P Expected	Mi (counts expected)	P Observed	Xi (counts observed)	x^2
Category 1					
Category i					
•••					
Category K					·
SUM	100%	n	100%	n	χ^2

מבחן קולומוגורוב- סמירנוב

K-S Test

- מבחן זה הוא לא פרמטרי, כלומר אינו מחייב אותנו שההתפלגויות יהיו נורמליות.
- במבחן זה נוכל להשוות בין התפלגויות של משתנים רציפים או נומריים (נשים לב שגם משתנים רציפים יכולים להיחשב כמשתנים קטגוריים ע"י חלוקת ערכיהם לבינום).
- מבחן זה הינו מבחן המשווה בין התפלגויות ובודק עד כמה הן דומות. אפשר להשוות בין שתי התפלגויות של שני מדגמים, או בין מדגם והתפלגות תיאורטית. במידה ואנחנו רוצים לבחון נורמליות, נשווה את ההתפלגות שהתקבלה במדגם להתפלגות נורמלית-תיאורטית, כלומר הפיזור של ערכי המדגם בתנאי נורמליות.
 - מבחן זה אינו קטגורי! הוא מתאים למשתנים רציפים או סדורים, כלומר שיש חשיבות לסדר a>b b>c c>d למשל שידוע (למשל שידוע b b>c c>d
 - השערות המבחן:

בהינתן 2 אוכלוסיות A ו-B נשאל:

.B כלומר $A \sim B$: HO

.B כלומר, $A \neq B$: H1

: כלל ההכרעה

הערך הקריטי שנקבע על סמך מבחן זה מחושב מתוך טבלת K-S ע"י ערכי רמת מובהקות וגודל המדגם.

 $D_c(\alpha, n)$

.רמת מובהקות $-\alpha$

. גודל המדגם (במקרה שמדובר בהשוואת התפלגות מול תיאוריה). -n

: מקרה ומדובר בשתי התפלגויות של מדגמים שונים A ו-B ננרמל את גודל המדגם ע"י החישוב

$$n = \sqrt{\frac{A+B}{A*B}}$$

Х	counts	Prob_Observed	Cdf_Obs	Prob_Expected (dnorm)	Cdf_Exp (pnorm)	Cdf_Obs-Cdf_Exp
Category 1						
•••				_		
בעמודה זו תהיה חלוקה לקבוצות/קטגוריות	כמות הדגימות שנצפו בכל קטגוריה במדגם	ההסתברות של קטגוריה זו ביחס למדגם כולו (Counts/n)	הסתברות מצטברת- סכום העמודה משמאל עד לקטגוריה המתאימה	ההסתברות של ההתפלגות התיאורטית אליה אנו משווים	הסתברות מצטברת של התיאוריה- סכום העמודה משמאל עד לקטגוריה המתאימה	מעמודה זו ניקח את הערך המקסימלי והוא ייצג את הערך <i>D_{max}</i>

 D_{max} – Maximum difference between observed cdf and expected cdf.

:לאחר שמצאנו את הערך של D_{max} נבדוק אם מתקיים

. נלקחת H1 נדחית והשערת H0 השערת $D_{max} > D_{c}$

לחילופין ניתן לבדוק אם מתקיים:

. השערת H1 נדחית והשערת H0 השערת P_v > α

^{**} נשים לב שטבלה זו בנויה בהתאמה למקרה בו אנו משווים התפלגות של מדגם כלשהו לתיאוריה.

מבחן חי בריבוע – Chi Squared Test

להשוואת משתנה קטגורי בכמה אוכלוסיות שונות

- נניח ש X משתנה קטגורי עם m קטגוריות שונות $x \in \{x_1, x_2, x_3, \dots, x_m\}$ נניח ש $x \in \{x_1, x_2, x_3, \dots, x_m\}$ לחץ דם, השמנת יתר , אנמיה)
 - המטרה במבחן זה היא להשוות את ההתפלגות של X בין X אוכלוסיות שונות $A \in \{A_1,A_2,A_3,\dots,A_K\}$
 - השערות המבחן:

. כלומר X כלומר , $A_1 \sim A_2 \sim ... \sim A_k$: H0 אינו מתפלג דומה בכל הקבוצות\האוכלוסיות. H1 : אחרת, כלומר X אינו מתפלג דומה בכל הקבוצות

- נשים לב שבמבחן זה מדובר בהשוואה בין מספר כלשהו X של אוכלוסיות בעוד שבמבחן a k-s מדובר בהשוואה של 2 התפלגויות בלבד. בנוסף מספר הקטגוריות במבחן k-s הוא הרבה יותר גדול כיוון ששם מחלקים משתנה שהוא רציף לקטגוריות. היחס בין הקטגוריות של X במבחן זה הוא שהן לא תלויות זו בזו בשונה מבמבחן k-s.
 - :נסמן

.j מספר התצפיות\דגימות בקטגוריה i באוכלוסייה – $O_{i \cdot i}$

j גודל המדגם באוכלוסייה $-n_i$

מספר התצפיות\דגימות הכולל בקטגוריה i בכל האוכלוסיות. $-t_i$

 $rac{o_{i \prime j}}{n_j}$:"י: באוכלוסייה j מחושב ע"י: i ההסתברות לקבל את מקרה קטגוריה i

 $\frac{t_i}{n}$: ע"י מחושבת מחושבת בכלל האוכלוסייה, מחושבת עריי - P_i

 $rac{t_i}{n}*n_j$: מספר הדגימות המצופה באוכלוסייה j בקטגוריה i תחת השערת ה0, מחושב ע"י $-E_{i\prime j}$

- שלבים:
- 1. נמלא את הטבלה הבאה על מספר התצפיות בכל מקרה לפי הנתונים:

Population	A ₁	A ₂	 A _j	 A _k	Total
Category					(t _i)
X ₁					t ₁
X ₂					t ₂
x _i			O _{i,j}		ti
x _m					t _m
Total (n _i)	n_1	n ₂	 n _i	 n _k	n

טבלת Observed

2. לאחר מילוי הטבלה על מספר התצפיות בכל מקרה נוכל לבנות טבלה חדשה שבה נציג את המידע של הטבלה הקודמת באחוזים של הסתברויות עבור כל מקרה:

$$P_{i'j} = \frac{O_{i'j}}{n_i}$$

Population	A_1	A ₁ A ₂	 A_{j}	 A_k	Total
Category			-		(t _i)
X ₁					t ₁
X ₂					t ₂
x _i			$P_{i'j}$		ti
x _m					t _m
Total (n _j)	n_1	n ₂	 n _j	 n _k	n

. chi squared על מנת להמשיך באנליזה נצטרך לבצע את מבחן חי בריבוע 3 על מנת נוכל לבצע מבחן זה צריכות להיות לנו observed וגם expected. הטבלה .expected ועתה ונצטרך לחשב טבלה בעבור observed שחישבנו בשלב כלומר בטבלה זו יופיע כמה אני תצפיות אני מצפה שיהיו בכל קטגוריה בהינתן גודל המדגם של כל אוכלוסייה.

$$E_{i'j} = \frac{t_i}{n} * n_j$$

Population	A_1	A ₂	 Aj	 A_k	Total
Category			1200		(t _i)
x ₁					t,
x ₂					t ₂
1222					
x _i			$E_{i'j}$		t,
•••					
x _m					t _m
Total (n _i)	n ₁	n ₂	 n _i	 n _k	n

טבלת Expected

בטבלה זו נשים לב:

אם ב- 80% מסך התאים בטבלה זו יש ערך 5 אם ב- 25 מסך התאים בטבלה זו יש אין אומר אומר בטבלה אומר אין מספיק מופעים במבחן זה וצריך לאחד קטגוריות.

: בשלב זה נחשב את x^2 ע"י הנוסחה .4

$$x_{i,j}^2 = \frac{(O_{i,j} - E_{i,j})^2}{E_{i,j}}$$

Population	A_1	A ₂	 A _j	 A_k	Total
Category	900				
X ₁					
x ₂					
x _i			$x_{i,j}^2$		
x _m					
Total x_j^2	x_1^2	x_3^2	 x_j^2	 x_k^2	X_{total}^2

 $: x^2$ ע"י טבלת x_c^2 נחשב את ערכו של

$$x_c^2 = x^2(df, 1-\alpha)$$

:או לחילופין ע"י תוכנת R והפונקציה הבאה

$$x_c^2 = qchisq(df, 1 - \alpha)$$

$$P_v = pchisq(x^2, df, tail = false)$$

. לבסוף בודקים: אם מתקיים א $P_v < lpha$ השערת והשערת 140 נלקחת.

מבחן להשוואת תוחלת בין שתי קבוצות לא מצומדות ע"י מבחן T

- קבוצות לא מצומדות קבוצות בלתי תלויות, כלומר בכל קבוצה יש נבחנים שונים. אנו מניחים כי אין
 קשר בין המדגם הראשון לבין המדגם השני, כל מדגם הוא מדגם מקרי מתוך אוכלוסייה.
 - מדגמים הם בלתי תלויים כאשר:
 - → המשתתפים נדגמים באופן אקראי מאוכלוסיות שונות.
 - → המשתפים נדגמו מאוכלוסייה אחת, אך הוקצו באופן אקראי לשתי קבוצות טיפול שונות.
 - מטרת המבחן היא לבחון את השאלה האם התוחלות\הממוצעים של שני המדגמים שונים זה מזה. במבחן למדגמים בלתי תלויים, אנחנו רוצים להסיק על הפרש הפרמטרים $\mu_1 \mu_2$ של התכונה הנחקרת.
 - :נשתמש במבחן זה כאשר
 - .(שוניות שוניות באוכלוסיות אינן ידועות שוויון שונויות אינן ידועות שוניות באוכלוסיות אינן ידועות שוויון שונויות $\sigma^2_{\ 2}, \sigma^2_{\ 1} \ \leftarrow$
 - המדגמים לא מצומדים \leftarrow
 - → המשתנים בכל אוכלוסייה מתפלגים נורמלית
- למרות שאיננו יודעים את $\sigma^2_{\ 2}, \sigma^2_{\ 1}$ על מנת שנוכל לקדם את בחינת השערת ההבדלים נפעל בהנחה : $\sigma^2_{\ 2}, \sigma^2_{\ 1}$ אחת לשנייה וגם לשונויות במדגמים בהמשך נלמד כיצד לבדוק זאת)

$$\sigma_2^2 = \sigma_1^2 = S^2 \leftarrow$$

- $.s^2_{~2}, s^2_{~1}$ הוא הממוצע המשוקלל של השונויות במדגמים $S^2 \ \leftarrow$
 - : נסמן
 - משתנה נורמלי $Y \leftarrow$
 - ממוצעי המדגמים $\overline{Y_2}, \overline{Y_1} \leftarrow$
 - סטיות התקן של המדגמים $S_{1,}S_{2}$
 - מדגמים בלתי תלויים $-n_1, n_2 \leftarrow$
 - רמת המובהקות α
 - : השערות המבחן

$$\mu_1 - \mu_2 = 0 \leftarrow \mu_1 = \mu_2$$
: H0

:H1 לגבי השערת המחקר ישנן כמה אפשרויות:

$$\mu_1 - \mu_2 < 0 \leftarrow \mu_1 < \mu_2$$

 $\mu_1 - \mu_2 > 0 \leftarrow \mu_1 > \mu_2$

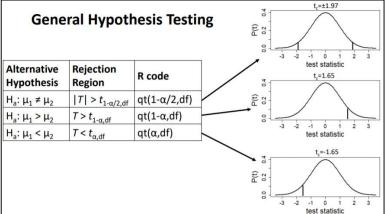
$$\mu_1 - \mu_2 \neq 0 \leftarrow \mu_1 \neq \mu_2$$

- חישוב שונות המדגמים המשוקללת:
 ממנה נוכל לחשב את סטיית התקן (=שורש השונות)
 - חישוב דרגות החופש:
 - •
 - $:t_{statistic}$ שישוב ערכו של ullet

 $S^{2} = \frac{(n_{1} - 1) \cdot S_{1}^{2} + (n_{2} - 1) \cdot S_{2}^{2}}{(n_{1} - 1) + (n_{2} - 1)}$

$$df = n_1 + n_2 - 2$$

$$T = \frac{\overline{Y_1} - \overline{Y_2}}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}} = \frac{\overline{Y_1} - \overline{Y_2}}{s \cdot \sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$$



• שלב ההכרעה:

נחשב את t_c לפי דרגות החופש ורמת המובהקות ונכריע את המבחן.

המספרים בגרפים רק להמחשת המיקום של $t_{c}\,$

במקרים אלו השערת H0 נדחית והשערת H1 נלקחת.

הבדלה בין מבחנים:

- 1. מצומד או לא מצומד(אם גודל המדגמים שונה זה בטוח לא מצומד)
 - 2. האם המידע נורמלי(נורמליות משותפת)

3

